

Klasifikasi Aksara Jawa Menggunakan Metode Convolutional Neural Network

Audiva Tartila Daning Putri¹

¹*Fakultas Ilmu Komputer, UPN "Veteran" Jawa Timur, Surabaya*

Abstract

This research aims to implement Convolutional Neural Network (CNN) for recognizing handwritten Javanese script characters. Javanese script exhibits diverse writing styles, posing challenges in character recognition, especially for less commonly used letters. CNN is employed to extract complex features from Javanese script character images. With an adequate dataset, the CNN model is trained to classify characters with high accuracy. Evaluation results on testing data show an accuracy of 96.25%, with minimal performance differences between training and testing data, indicating the absence of significant overfitting. In conclusion, the CNN model successfully generalizes well to new data, providing an efficient and accurate solution for recognizing handwritten Javanese script characters.

Keywords: Javanese Alphabet, Convolutional Neural Network, Character Recognition, Handwriting.

Abstrak

Penelitian ini bertujuan mengimplementasikan Convolutional Neural Network (CNN) untuk pengenalan karakter aksara Jawa tulisan tangan. Aksara Jawa memiliki variasi gaya penulisan yang memunculkan kesulitan dalam pengenalan karakter, terutama untuk huruf jarang digunakan. CNN digunakan untuk mengekstraksi fitur-fitur kompleks dari gambar karakter aksara Jawa. Dengan melibatkan dataset yang memadai, model CNN dilatih untuk mengklasifikasikan karakter dengan akurasi tinggi. Hasil evaluasi pada data testing menunjukkan akurasi sebesar 96.25% dengan perbedaan performa yang minimal antara data training dan data test, menunjukkan ketidakadaan overfitting yang signifikan. Kesimpulannya, model CNN berhasil menggeneralisasi dengan baik pada data baru, memberikan solusi efisien dan akurat untuk pengenalan karakter aksara Jawa tulisan tangan.

Kata Kunci: Aksara Jawa, Convolutional Neural Network, Pengenalan Karakter, Tulisan Tangan.

I. INTRODUCTION

Kekayaan warisan sejarah Indonesia, termasuk bangunan-bangunan, prasasti, karya sastra, dan lainnya, merupakan warisan yang ditinggalkan oleh para leluhur. Aksara Jawa, sebagai salah satu bagian dari warisan ini, telah mendapatkan pengakuan internasional dari Unicode, sebuah lembaga di bawah naungan UNESCO. Meskipun pengakuan ini memiliki dampak positif dalam melindungi aksara Jawa dari klaim pihak lain dan mengurangi risiko kepunahan, tantangan terkini adalah minimnya penggunaan aksara Jawa dalam kehidupan sehari-hari, khususnya di kalangan masyarakat Jawa sendiri. Hal ini menyebabkan banyak individu kesulitan menulis aksara Jawa karena mereka lupa cara penulisannya yang rumit dan sulit diingat.

Aksara Jawa terdiri dari 20 jenis karakter huruf dasar yang sering disebut sebagai aksara "carakan" atau "nglegena". Beragam gaya dan karakter penulisan menciptakan kebingungan dalam mengenali huruf-huruf tersebut dalam sebuah tulisan. Hal ini dapat menyebabkan kesalahpahaman dan penafsiran yang salah bagi pembaca, terutama ketika menulis huruf-huruf yang jarang digunakan sehari-hari seperti aksara Jawa.

Untuk membantu mengatasi kesulitan ini, pendekatan berbasis pemrosesan gambar seperti Pengenalan Karakter Tulisan Tangan (*Handwritten Character Recognition*) dapat memudahkan orang dalam mengenali karakter-karakter aksara Jawa. Melalui teknologi ini, komputer dapat mengenali dan

memproses karakter tulisan tangan dari gambar yang diambil dari dokumen, gambar, dan media lainnya. Salah satu metode yang dapat digunakan adalah CNN, yang merupakan jenis arsitektur jaringan syaraf tiruan yang umumnya digunakan dalam pengenalan pola visual, seperti pengenalan gambar atau karakter. CNN belajar dari dataset gambar karakter Jawa tulisan tangan yang diberikan dengan memperhatikan pola-pola yang muncul. Setelah dilatih dengan dataset tersebut, CNN diharapkan dapat mengenali dan mengklasifikasikan karakter Jawa tulisan tangan yang belum pernah dilihat sebelumnya dengan tingkat akurasi yang tinggi.

II. LITERATURE REVIEW

2.1 Penelitian terdahulu

Terdapat beberapa penelitian yang berkaitan dengan pengenalan karakter tulisan tangan, seperti pengenalan angka dan huruf. Penelitian tersebut menggunakan berbagai metode dalam mengklasifikasikan data dan mengekstraksi fitur sebagai parameter. Dari beberapa penelitian terdahulu, peneliti memilih beberapa untuk dijadikan referensi yang relevan dengan penelitian yang akan dilakukan. Menurut M. Sudarma dan I. Surya Darma [3]. Naskah papirus merupakan peninggalan sejarah Bali yang perlu dilestarikan dan dirawat karena beberapa naskah sudah rusak atau rapuh. Di dalam naskah papirus terdapat tulisan yang menggunakan aksara Bali. Oleh karena itu, penelitian dilakukan untuk mengidentifikasi aksara Bali dengan menggunakan K-Nearest Neighbor (K-NN) dan ekstraksi fitur semantik. Fitur semantik menunjukkan bentuk aksara Bali yang terdiri dari garis vertikal dan garis horizontal, titik akhir tulisan, garis yang membentuk iterasi, jumlah baris, dan jumlah kolom. Penelitian tersebut Hasil penelitian memperoleh akurasi sebesar 88,89%, dimana masih terdapat aksara yang diklasifikasikan secara tidak benar karena fitur yang diperoleh dari masing-masing karakter memiliki kemiripan. Contohnya huruf Ca dan Sa.

Sistem penulisan bahasa Jepang memiliki tiga set karakter yang berbeda, yaitu Hiragana, Katakana dan Kanji. Menurut Chaerul Umam dan Lekso Budi Handoko [4], kata Jepang Hiragana kebanyakan digunakan untuk morfem gramatikal. Teks bahasa Jepang tidak memiliki pembatas seperti spasi, kata yang berbeda. Selain itu, beberapa karakter dalam alfabet dapat menjadi morfik, yaitu memiliki definisi bentuk yang serupa yang dapat menambah kompleksitas proses pengenalan. Convolutional Neural Network (CNN) adalah arsitektur jaringan neural dalam yang banyak digunakan untuk klasifikasi gambar dan telah menghasilkan hasil yang canggih dalam beberapa tugas klasifikasi gambar. CNN dipilih karena lebih unggul dalam melakukan analogi dibanding Support Vector Machine (SVM) maupun K-Nearest Neighbor (KNN). Percobaan menggunakan 50 huruf hiragana dengan masing-masing huruf terdapat 20 pengujian citra, sehingga total dataset adalah 1000 citra. Hasil yang diperoleh dalam proses pemeriksaan yaitu 82%, dengan sebaran 120 citra tidak terdeteksi dengan benar dan 880 citra terdeteksi benar.

Menurut hasil penelitian yang dilakukan oleh Ivan Sukma Hanindria dan Hendry [5] terkait klasifikasi Aksara Jawa menggunakan metode Convolutional Neural Network (CNN), metode ini telah berhasil mencapai tingkat akurasi sebesar 85% dalam mengklasifikasikan citra Aksara Jawa. Dalam perbandingan dengan metode lain, seperti KNN (K-Nearest Neighbors) yang diimplementasikan melalui alat bantu Orange, diketahui bahwa akurasi yang dihasilkan masih berada di bawah akurasi yang diperoleh dengan menggunakan metode CNN, yakni sebesar 84.7%. Dengan demikian, dapat disimpulkan bahwa dari segi akurasi, penggunaan metode CNN menunjukkan keunggulan dibandingkan dengan metode KNN dan metode lainnya yang diuji dalam penelitian tersebut.

2.2 Aksara Jawa

Aksara Jawa merupakan peninggalan sejarah dalam bentuk tulisan yang sudah ada sejak abad ke-17 atau pada masa pemerintahan Mataram Kuno. Pada masa itu masyarakat menggunakan aksara Jawa sebagai bahasa sehari-hari. Aksara Jawa sendiri secara umum memiliki aksara dasar atau biasa juga disebut sebagai aksara "carakan" atau "nglegena" [6].



Gambar 1. Aksara Jawa

Berdasarkan Gambar 1, aksara Jawa terdiri dari 20 huruf dengan tingkat kesulitan yang berbeda dan beberapa huruf memiliki kemiripan. Selain aksara dasar "carakan", terdapat juga aksara murda, aksara suara, aksara fiktif, aksara sandhangan, aksara pra-tanda, dan aksara pasangan.


2.3 CNN

Convolutional Neural Networks (CNN) merupakan jenis arsitektur jaringan syaraf tiruan yang digunakan untuk menganalisis dan mengenali pola pada citra. CNN terdiri dari lapisan-lapisan yang menjalankan operasi konvolusi untuk mengekstraksi fitur-fitur utama dari gambar. Dalam konteks pengenalan karakter aksara Jawa, CNN dapat dimanfaatkan untuk mengenali pola-pola kompleks yang terdapat pada bentuk-bentuk aksara tersebut. Prosesnya dimulai dengan memproses citra aksara Jawa sebagai input. Selanjutnya, melalui serangkaian lapisan konvolusi, CNN secara bertahap mengidentifikasi fitur-fitur krusial seperti lengkungan, garis, atau pola unik dari setiap karakter aksara. Dengan memanfaatkan dataset yang cukup representatif, CNN dapat melakukan klasifikasi dengan tingkat akurasi yang tinggi. Hal ini membuka peluang untuk meningkatkan efisiensi dan akurasi pengenalan karakter aksara Jawa melalui penerapan teknologi berbasis pembelajaran mesin. Penerapan teknologi berbasis pembelajaran mesin, seperti CNN, membawa dampak positif dalam meningkatkan efisiensi dan akurasi pengenalan karakter aksara Jawa. Ini menciptakan solusi yang lebih baik dan dapat diandalkan dalam memahami serta menginterpretasikan beragam bentuk tulisan aksara Jawa secara efektif.

III. RESEARCH METHOD

3.1 Alur Penelitian

Penelitian ini dimulai dengan tahap identifikasi masalah, di mana peneliti secara cermat mengidentifikasi permasalahan yang menjadi fokus utama penelitian ini. Langkah berikutnya melibatkan perancangan konsep model yang akan menjadi landasan utama dalam melakukan klasifikasi terhadap Aksara Jawa. Proses pengumpulan data merupakan tahapan krusial, di mana dataset Aksara Jawa menjadi sumber utama untuk menciptakan model klasifikasi. Dataset ini digunakan sebagai input dan output dalam proses pelatihan dan pengujian model. Untuk memastikan konsistensi dan keakuratan, tahap preprocessing diterapkan guna menyamakan ukuran citra dalam dataset, sehingga model dapat mengenali pola dengan lebih baik dan efisien. Langkah selanjutnya melibatkan proses pelatihan dan pengujian menggunakan data latih dan data uji. Proses ini merupakan inti dari pengembangan model klasifikasi Aksara Jawa. Setelah mendapatkan hasil dari pengujian, dilakukan analisis mendalam terhadap output yang dihasilkan. Hal ini bertujuan untuk mengevaluasi akurasi dan ketepatan klasifikasi gambar Aksara Jawa yang dihasilkan oleh model yang dikembangkan. Untuk alur penelitian dapat dilihat pada Gambar 2.



Gambar 2. Flowchart Alur Penelitian

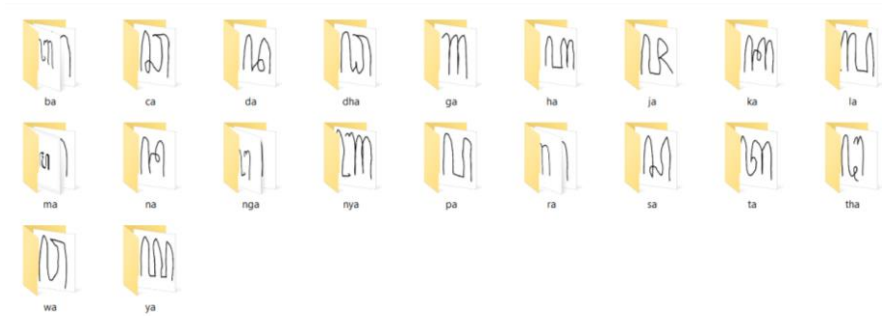
3.2 Pengumpulan Data

Dataset yang digunakan dalam penelitian ini terdiri dari total 4419 gambar tanda tangan aksara Jawa yang diambil dari Kaggle. Pembagian dataset mencakup 3120 gambar untuk data latih yang terbagi dalam 20 kelas, dengan masing-masing kelas memiliki 156 contoh gambar. Sementara itu, data uji terdiri dari 1299 gambar yang juga terbagi dalam 20 kelas, dengan 65 gambar pada setiap kelasnya. Ketersediaan jumlah yang seimbang dari setiap kelas diharapkan dapat mendukung proses pelatihan dan evaluasi model klasifikasi untuk mengidentifikasi berbagai variasi dari aksara Jawa dengan baik.



Gambar 3. Aksara Jawa "ba"


Seperti yang ada pada Gambar 3, nantinya setiap gambar dalam dataset ini memiliki ukuran sebesar 300 pixel, memastikan konsistensi dalam resolusi yang digunakan untuk setiap contoh gambar aksara Jawa.



Gambar 4. Dataset Aksara Jawa

3.3 CNN

Arsitektur CNN (Convolutional Neural Network) adalah model jaringan saraf tiruan yang terinspirasi oleh cara visual manusia memproses informasi. CNN terdiri dari beberapa lapisan yang berbeda untuk mengekstraksi fitur dari data visual, seperti gambar. Lapisan-lapisan tersebut meliputi lapisan konvolusi, lapisan aktivasi, lapisan pooling, dan lapisan fully connected. Lapisan konvolusi bertanggung jawab atas ekstraksi fitur dengan melakukan operasi konvolusi pada input gambar menggunakan filter atau kernel untuk mendeteksi pola-pola tertentu. Gambar 2.4 merupakan arsitektur CNN.



Gambar 5. Arsitektur CNN

Dari Gambar 5, dapat dilihat bahwa sebelum diproses dalam pengklasifikasi (*classifier*), input untuk CNN akan diproses dalam dua tahap. Kedua tahap tersebut terdiri dari operasi konvolusi (*convolution*) dan subsampling. Terlihat juga bahwa kedua operasi tersebut akan mengurangi dimensi dari input. Operasi konvolusi akan mengubah sebuah matriks masukan dua dimensi menjadi beberapa matriks dua dimensi yang lebih kecil atau feature map. Pada akhir tahap kedua, dilakukan fungsi untuk meratakan atau mengubah setiap feature map dari matriks dua dimensi menjadi matriks satu dimensi sehingga feature map siap untuk diklasifikasikan dengan jaringan neural terhubung sepenuhnya.

IV. RESULTS AND DISCUSSION

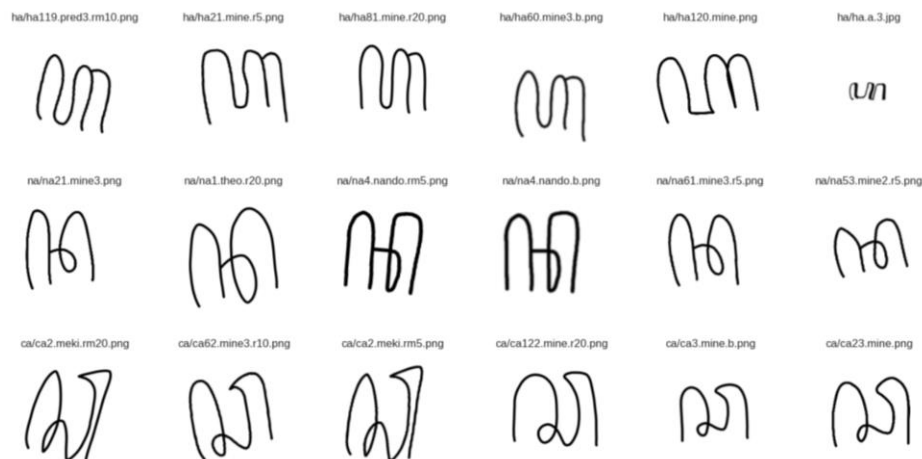
4.1 Mempersiapkan Dataset

Penelitian ini berfokus pada eksplorasi kemampuan Convolutional Neural Network (CNN) dalam mengklasifikasikan gambar ke dalam 20 kelas yang ditetapkan, yaitu ha, na, ca, ra, ka, da, ta, sa, wa, la, pa, dha, ja, ya, nya, ma, ga, bha, tha, dan nga. Proses penelitian melibatkan penggunaan 100 epoch untuk melatih model yang akan mampu mengidentifikasi setiap gambar dari kelas ha hingga nga. Pendekatan ini

memanfaatkan beberapa library seperti os, time, numpy, matplotlib, tensorflow, dan CNN untuk mengoptimalkan proses klasifikasi gambar secara efektif.

4.2 Preprocessing

Dalam tahap ini, langkah awal melibatkan pengambilan gambar dari file berformat .png yang merupakan tanda tangan aksara Jawa. Kemudian, proses dilanjutkan dengan mengonversi gambar tersebut menjadi citra keabu-abuan (grayscale), yang mana tujuan utamanya adalah untuk menyederhanakan tanda tangan ke dalam bentuk yang tidak mengandung warna. Setelahnya, langkah selanjutnya adalah mengubah citra keabu-abuan tersebut menjadi citra biner, di mana hanya terdapat dua nilai piksel yang mungkin (hitam dan putih). Tujuan utama dari proses preprocessing ini adalah untuk menghasilkan gambar yang bersih setelah proses pemindaian serta untuk mengurangi ukuran file dengan mengubahnya ke dalam citra keabu-abuan, sehingga memperkecil ukuran file tersebut. Hal ini diharapkan dapat mempercepat proses komputasi pada langkah-langkah selanjutnya. Dilakukan pengaturan dua set transformasi untuk gambar. Yang pertama untuk data latihan seperti yang ada pada Gambar 6 dengan rotasi hingga 20 derajat, zoom 20%, dan miringan 10%, serta penyesuaian ukuran. Dan yang kedua hanya untuk validasi dengan penyesuaian ukuran. Kedua set ini diarahkan pada direktori yang berbeda untuk latihan dan validasi, dengan pengaturan yang sama untuk ukuran gambar, ukuran batch, mode warna grayscale, dan klasifikasi kategori pada output.



Gambar 6. Data Training

4.3 Plotting

Dilakukan plotting untuk membuat grafik visualisasi dari riwayat pelatihan sebuah model. Fungsi ini menerima input yang merupakan riwayat hasil pelatihan model. Pertama, fungsi ini membuat gambar dengan ukuran tertentu. Kemudian, pada subplot pertama, grafik menampilkan perubahan nilai loss pada setiap epoch untuk data pelatihan dan validasi. Pada subplot kedua, grafik menunjukkan perubahan akurasi pada setiap epoch untuk data pelatihan dan validasi. Fungsi ini mengembalikan grafik untuk visualisasi yang lebih jelas.

4.4 Testing

Testing ini digunakan untuk menguji model klasifikasi pada gambar-gambar baru yang terdapat dalam suatu direktori. Pertama, daftar path dari gambar-gambar uji diambil dari direktori. Selanjutnya, untuk setiap gambar di direktori tersebut, gambar di-load menggunakan Keras, diubah ke dalam format array, dan diubah ukurannya sesuai dengan ukuran yang ditentukan. Proses prediksi dilakukan menggunakan model yang diberikan pada gambar yang telah dipersiapkan. Hasil prediksi diinterpretasikan sebagai kelas yang sesuai dari daftar kelas yang telah ditentukan sebelumnya. Selain itu, gambar juga ditampilkan untuk diperiksa secara visual.

4.5 Pembuatan Model

Pada sistem CNN, model dibangun dengan beberapa lapisan yang meliputi layer konvolusi untuk melakukan operasi konvolusi pada input, layer pooling untuk mengurangi dimensi spasial dari feature map, layer dropout untuk mengurangi overfitting, layer flatten untuk mengubah feature map menjadi vektor satu dimensi, dan layer dense yang berperan dalam pengambilan keputusan berdasarkan informasi yang terkandung dalam vektor hasil flatten. Fungsi aktivasi yang digunakan adalah Rule.

Hasil dari proses konvolusi menghasilkan feature map yang kemudian digunakan dalam proses konvolusi berikutnya secara berulang. Output dari model ini merupakan hasil dari proses pengambilan keputusan atau klasifikasi yang dilakukan oleh model, yang dihasilkan setelah proses pelatihan model dengan menggunakan lapisan-lapisan tersebut.

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 222, 222, 16)	160
max_pooling2d (MaxPooling2D)	(None, 111, 111, 16)	0
conv2d_1 (Conv2D)	(None, 109, 109, 32)	4640
max_pooling2d_1 (MaxPooling2D)	(None, 54, 54, 32)	0
conv2d_2 (Conv2D)	(None, 52, 52, 32)	9248
max_pooling2d_2 (MaxPooling2D)	(None, 26, 26, 32)	0
conv2d_3 (Conv2D)	(None, 24, 24, 64)	18496
max_pooling2d_3 (MaxPooling2D)	(None, 12, 12, 64)	0
conv2d_4 (Conv2D)	(None, 10, 10, 64)	36928
max_pooling2d_4 (MaxPooling2D)	(None, 5, 5, 64)	0
flatten (Flatten)	(None, 1600)	0
dropout (Dropout)	(None, 1600)	0
dense (Dense)	(None, 128)	204928
dense_1 (Dense)	(None, 20)	2580
Total params: 276980 (1.06 MB)		
Trainable params: 276980 (1.06 MB)		
Non-trainable params: 0 (0.00 Byte)		

Gambar 7. Output Klasifikasi

4.6 Proses Training


Pada sistem ini, proses training dilakukan dengan menggunakan 100 kali iterasi atau epoch. Evaluasi dilakukan terhadap validation data setiap kali satu epoch selesai. Dari hasil uji coba yang tercatat dalam Tabel 1, dapat disimpulkan bahwa semakin banyak iterasi yang dilakukan, nilai loss cenderung semakin berkurang dan nilai akurasi cenderung meningkat. Hal ini menggambarkan bahwa dengan meningkatnya jumlah iterasi, performa model cenderung membaik dengan penurunan loss dan peningkatan

akurasi pada data validasi. Ini menunjukkan bahwa model semakin mampu mengenali dan mengklasifikasikan data dengan lebih tepat seiring berjalannya proses pelatihan. mungkin memberikan penjelasan lebih lanjut tentang hubungan antara jumlah iterasi dengan performa model tersebut.

Tabel 1. Epoch dari Hasil Uji Coba

Epoch	Train Loss	Train Akurasi	Validasi Loss	Validasi Akurasi
1	2.9988	0.0489	2.9912	0.0479
2	2.9160	0.0849	2.3076	0.2917
3	2.1006	0.3540	1.3565	0.6094
99	0.0397	0.9862	0.2103	0.9510
100	0.0253	0.9903	0.1954	0.9625

4.7 Hasil



Gambar 8. Hasil Evaluasi

Dari hasil evaluasi pada data testing, didapatkan nilai akurasi pada data training sebesar 0.0253 untuk loss dan 0.9903 untuk akurasi. Sementara itu, pada data test, nilai loss sebesar 0.1954 dan akurasi sebesar 0.9625. Hal ini menunjukkan bahwa model cenderung memberikan hasil yang baik pada data testing dengan akurasi yang tinggi, meskipun terdapat sedikit perbedaan performa antara data training dan data test.

Dalam konteks ini, nilai akurasi pada data test sebesar 0.9625 menunjukkan bahwa model yang telah dilatih mampu mengklasifikasikan data test dengan akurasi sekitar 96.25%. Perbedaan antara hasil akurasi data training dan data test yang tidak terlalu jauh juga menunjukkan bahwa model tidak mengalami overfitting yang signifikan terhadap data training. Ini adalah indikasi positif bahwa model mampu menggeneralisasi dengan baik pada data baru yang belum pernah dilihat sebelumnya.

V. Conclusion

5.1 Kesimpulan

Dalam penelitian ini, fokus utama ditempatkan pada kemampuan Convolutional Neural Network (CNN) dalam mengklasifikasikan tanda tangan aksara Jawa ke dalam 20 kelas yang telah ditetapkan. Proses eksplorasi ini melibatkan penggunaan 100 epoch untuk melatih model guna mengidentifikasi setiap gambar dari kelas yang ditentukan. Langkah awal dalam preprocessing melibatkan konversi gambar ke dalam citra keabu-abuan dan citra biner, tujuannya adalah untuk menyederhanakan gambar dan mempercepat proses komputasi. Hasil evaluasi pada data testing menunjukkan akurasi model sekitar 96.25%, menegaskan keberhasilan model dalam mengklasifikasikan data baru dengan tingkat keakuratan yang tinggi. Meskipun terdapat sedikit perbedaan performa antara data training dan data test, model secara keseluruhan tidak mengalami overfitting yang signifikan. Rekomendasi untuk penelitian selanjutnya mencakup perluasan dataset dengan variasi yang lebih luas, eksperimen dengan arsitektur model berbeda, serta eksplorasi transformasi gambar tambahan guna meningkatkan kemampuan model dalam mengenali tanda tangan aksara Jawa dengan lebih baik.

5.2 Saran

Pengembangan lebih lanjut pada penelitian ini dapat difokuskan pada beberapa aspek kunci. Pertama, perluasan dataset dengan variasi yang lebih luas dari setiap kelas akan memberikan kedalaman pada pembelajaran model terhadap situasi yang berbeda. Eksperimen dengan arsitektur model yang berbeda juga bisa menjadi langkah maju untuk mengevaluasi apakah terdapat arsitektur yang lebih efektif dalam mengenali tanda tangan aksara Jawa. Penggunaan teknik regularisasi seperti dropout atau augmentasi data lebih lanjut dapat membantu dalam mengurangi overfitting. Selain itu, eksplorasi transformasi gambar tambahan atau teknik augmentasi data lebih lanjut juga bisa menjadi fokus untuk meningkatkan keakuratan model. Analisis yang lebih mendalam terhadap decision boundary atau kesalahan model juga akan memberikan wawasan yang berharga. Terakhir, optimisasi hyperparameter dapat menjadi langkah penting dalam menyetel model untuk performa yang lebih baik.

REFERENCES

- [1] Susanto, A., Sari, C. A., Mulyono, I. U. W., & Doheir, M. (2021). Histogram of gradient in K-Nearest Neighbor for Javanese alphabet classification. *Scientific Journal of Informatics*, 8(2), 289-296.
- [2] Kusetogullari, H. (2018). Unsupervised text binarization in handwritten historical documents using k-means clustering. In *Proceedings of SAI Intelligent Systems Conference (IntelliSys) 2016: Volume 2* (pp. 23-32). Springer International Publishing.
- [3] M. Sudarma and I. W. A. Surya Darma, "The identification of balinese script characters based on semantic features and k-Nearest Neighbor," *Int. J. Comput. Appl.*, vol. 91, no. 1, pp. 14-18, 2014.
- [4] Umam, C. and Budi Handoko, L. (2020) 'Convolutional Neural Network (CNN) Untuk Identifikasi Karakter Hiragana', *Prosiding Seminar Nasional Lppm Ump*, 0(0), pp. 527-533.
- [5] Ivan Sukma Hanindria and Hendry, "Pengklasifikasian Aksara Jawa Metode Convolutional Neural Network", *JATISI (Jurnal Teknik Informatika dan Sistem Informasi)*, vol. 9, no. 3, 2727-2737, 2022.
- [6] J. K. Author, "Title of dissertation", Ph.D. dissertation, Abbrev. Dept., Abbrev. Univ., City of Univ., Abbrev. State, (year).